Снижение дисперсии в A/B-тестах: CUPED, CUPAC, регрессия Лина и ML-RATE

Обзор, выбор метода по умолчанию и статистический вывод

Иван Юрашку
VarWar R&D

октябрь 2026

Главное.
- CUPED, CUPAC, ANCOVA, регрессия Лина и ML-RATE решают одну задачу: убрать из оценки эффекта шум, объяснимый данными *до* эксперимента. Они различаются двумя решениями: *на что* корректировать (сырые признаки или ML-прогноз) и *как* (общий коэффициент или раздельные наклоны в группах). OLS — лишь способ подгонки, а не отдельный метод.
- **Метод по умолчанию — регрессия Лина**: OLS с центрированными предпериодными ковариатами и их взаимодействиями с группой, робастная стандартная ошибка HC2 и t-распределение. Асимптотически он не хуже разности средних при любом сплите. Без ковариат его стандартная ошибка совпадает с ошибкой теста Уэлча.
- При сплите 50/50 *или* одинаковой связи метрики с прошлым в обеих группах CUPED, ANCOVA и Лин практически совпадают. При неравном сплите *и* разной связи CUPED и ANCOVA могут быть хуже простой разности средних, Лин — нет. При нелинейном сигнале и большой выборке может выиграть ML-RATE (прогноз бустинга + регрессия Лина).
- Выигрыш: нужный объём выборки уменьшается в $1/(1-R^2)$ раз, где R^2 — доля дисперсии метрики, объяснённая данными до эксперимента. При очень малых группах HC2 заменяют на более консервативную HC3.
- Проверка на синтетических данных ($n = 200$, $R^2 = 0.4$, 1000 симуляций): у Лина доля ложных срабатываний 0.048 при номинале 0.05, покрытие 95%-интервала 0.954, MSE на 37% ниже, чем у разности средних (теория даёт $\approx 38\%$). В быстром прогоне по 24 сценариям MSE значимо ниже в 20, в трёх выигрыш в пределах шума, в одном (нет сигнала, $n = 200$) — проигрыш 6%.

1. Обзор: что общего и чем отличаются методы

Разность средних $\bar{Y}_1 - \bar{Y}_0$ — несмещённая, но шумная оценка эффекта. Если о каждом пользователе есть информация до эксперимента (значение метрики за прошлый период, признаки), можно вычесть ту часть разброса, которая ею объясняется, и получить более точную оценку. Все рассматриваемые методы делают именно это и различаются двумя решениями.

Решение 1: на что корректировать.

(a) На **сырые предпериодные признаки** X: прошлое значение метрики, возраст, регион и т. п.

(b) На **один ML-прогноз** $\hat{g}(X)$: модель предсказывает метрику по многим признакам, и корректировка идёт на этот прогноз.

Решение 2: как корректировать. Обозначим ковариату через Z (это X или $\hat{g}$), группу — через $T \in \{0, 1\}$.

(i) **Преобразовать метрику, затем обычный t-тест**: $Y^* = Y - \theta(Z - \bar{Z})$ с общим для обеих групп θ, затем тест Уэлча на Y^*.

(ii) **Регрессия с общим наклоном** $Y \sim T + Z$ (ANCOVA).

(iii) **Регрессия с раздельными наклонами** $Y \sim T + (Z - \bar{Z}) + T \cdot (Z - \bar{Z})$ с робастной стандартной ошибкой — *регрессия Лина*.

Сочетания этих решений и дают известные названия (табл. 1):

Таблица 1. Карта терминов.

	(i) преобразовать Y + Уэлч	(ii) регрессия, общий наклон	(iii) регрессия с взаимодействиями
(a) сырые признаки X	**CUPED** (Deng et al., 2013); для нескольких ковариат — multi-CUPED	**ANCOVA** («просто OLS»)	**регрессия Лина** (Lin, 2013)
(b) ML-прогноз $\hat{g}(X)$	**CUPAC** (Poyarkov et al., 2016; Li, 2020)	CUPAC в регрессии без взаимодействия	**ML-RATE** (Guo et al., 2021)

- **OLS** — метод наименьших квадратов. Им подгоняются (ii) и (iii), им же считается θ в CUPED. Сам по себе он эффект не определяет; «посчитали через OLS» в A/B обычно означает ANCOVA $Y \sim T + X$.
- **CUPED** $\approx$ ANCOVA с одной ковариатой (обычно лагом метрики): $\theta = \mathrm{Cov}(Y, Z)/\mathrm{Var}(Z)$ — OLS-наклон по всей выборке.
- **CUPAC** — тот же CUPED, но вместо прошлой метрики подставлен ML-прогноз. Меняется ответ на вопрос «на что», а не «как». Идея регрессии на прогноз бустинга опубликована Poyarkov et al. (2016), название CUPAC дал Li (2020).
- **Регрессия Лина** — ответ на вопрос «как». В группах свои наклоны, ковариаты центрированы, стандартная ошибка робастная. Это даёт оптимальный общий коэффициент и гарантию «асимптотически не хуже разности средних» (раздел 2).
- **ML-RATE** (в оригинале MLRATE, Guo et al., 2021) — прогноз в духе CUPAC, обученный с cross-fitting (см. раздел 4), и регрессия Лина поверх него: правый нижний угол таблицы.

Почему по умолчанию — Лин.

1. Асимптотически он не хуже разности средних при любом сплите и любой неоднородности эффекта. У CUPED и ANCOVA такой гарантии нет.
2. При сплите 50/50 или одинаковых наклонах он совпадает с CUPED на тех же ковариатах, так что переход ничего не стоит там, где CUPED уже работает.
3. Без ковариат его оценка и стандартная ошибка совпадают с тестом Уэлча: это прямое обобщение базового теста.
4. Одна OLS-регрессия: без ML-моделей и подбора гиперпараметров.

Цена — $2K + 2$ параметров. При малой выборке и бесполезных ковариатах выигрыш может стать слегка отрицательным, а нелинейную зависимость метрики от признаков Лин не ловит.

Когда разница реально важна.

1. *Сплит 50/50 или одинаковые наклоны в группах.* В пределах одной строки таблицы 1 все столбцы дают почти одно и то же: CUPED $\approx$ ANCOVA $\approx$ Лин.
2. *Неравный сплит и разная связь метрики с прошлым в группах* (эффект неоднороден). Столбцы (i) и (ii) смешивают наклоны с неправильными весами и могут оказаться хуже разности средних: это критика Freedman (2008). Столбец (iii) — нет. В намеренно крайнем примере (сплит 20/80; в контроле метрика полностью определяется прошлым, в тестовой группе от него не зависит) дисперсия CUPED и ANCOVA составила 1.40–1.42 от дисперсии разности средних, а дисперсия Лина — 0.95 (раздел 5).
3. *Нелинейный сигнал и большая выборка.* Строка (b) может выиграть у строки (a). В проверке на стенде (300 парных симуляций, нелинейный сценарий, $n = 2000$) у ML-RATE с бустингом MSE на 16–18% ниже, чем у Лина (95% интервал отношения MSE 0.75–0.93). В линейном сценарии при $n = 200$ бустинг, наоборот, проигрывает около 20% (10–33%): на маленьких фолдах прогноз недообучается.
4. *Где обучен прогноз $\hat{g}$* (только строка (b)). Прогноз для пользователя не должен использовать ни его группу, ни его собственный исход (раздел 4). Модель, обученная на исходах эксперимента и применённая к тем же строкам, «съедает» часть эффекта.

1.1. Стандартные ошибки в двух словах

Точечную оценку Лина даёт OLS, а стандартную ошибку — отдельная формула. Классическая OLS-ошибка предполагает одинаковый разброс остатков у всех наблюдений. В A/B-тестах это почти всегда нарушено, поэтому используют *робастные* (сэндвич) ошибки семейства HC0–HC3 (White, 1980; MacKinnon and White, 1985). Они отличаются поправкой на «рычаг» наблюдения — то, насколько сильно оно само тянет на себя линию регрессии.

- **HC0** — исходная формула Уайта; на малых выборках занижает ошибку.
- **HC1** — HC0 с общей поправкой на число параметров; опция `robust` в Stata.

- **HC2** — поправка на рычаг каждого наблюдения. Без ковариат в точности равна ошибке теста Уэлча. **Выбор по умолчанию.**
- **HC3** — более сильная поправка, консервативнее HC2; для очень малых групп.

На больших выборках все четыре совпадают. Формулы и численная проверка — в разделе 3.

1.2. Когда что использовать

Практические рекомендации по типичным ситуациям сведены в табл. 2. Общие правила для всех методов:

- ковариаты — *строго до воздействия*, список фиксируется до эксперимента;
- единица анализа совпадает с единицей рандомизации;
- ML-модель не видит группу пользователя и не использует его собственный исход.

Таблица 2. Практические рекомендации.

Ситуация	Рекомендация
Типичный тест: есть лаг метрики и несколько сильных предпериодных признаков	**Лин + HC2** на лаге и 2–5 признаках. Вариант по умолчанию.
Сплит 50/50, в продакшене уже CUPED по лагу	Можно оставить CUPED + Уэлч: при 50/50 его оценка асимптотически совпадает с оценкой Лина *на том же лаге*. Если наклоны в группах различаются, ошибка по Y^* чуть шире, чем HC2 Лина: CUPED остаётся валидным, но слегка консервативным. Лин с дополнительными признаками точнее. Важно, чтобы ошибка считалась по скорректированной метрике Y^* и $\theta = \mathrm{Cov} \,/\, \mathrm{Var}$.
Неравный сплит (10/90, 20/80)	**Лин** или **ML-RATE**. Если при этом связь метрики с прошлым в группах различается, CUPED и ANCOVA с общим θ теряют точность и могут оказаться хуже разности средних.
Много признаков, нелинейные зависимости, n от нескольких тысяч	**ML-RATE**: прогноз бустинга с cross-fitting; лаг метрики — и в признаках модели, и второй ковариатой финальной регрессии. При n в сотни — Лин.
Очень малые группы	HC2 откалибрована, пока в меньшей группе хотя бы $\sim$4–5 наблюдений на параметр группы ($K+1$); иначе **HC3** или HC2 со степенями свободы Белла–Маккаффри. При слабом сигнале ($R^2 \approx 0$) — простой тест Уэлча.
Тяжёлые хвосты (выручка)	Лин валиден в той же мере, что и тест Уэлча: оба опираются на ЦПТ, и при сильной асимметрии и маленьких группах покрытие обоих проседает. Выигрыш определяется корреляцией с прошлым и в сценариях с тяжёлыми хвостами сохранился. Ковариаты можно логарифмировать и клиппировать; винзоризация *самой метрики* меняет оцениваемую величину, её порог фиксируется заранее по предпериоду.
Ratio-метрики (CTR, средний чек)	Линеаризация на уровне пользователя: $L_i = Y_i - \hat{\kappa} N_i$, $\hat{\kappa} = \bar{Y}_0 / \bar{N}_0$ (Budylin et al., 2018), затем Лин на L_i. Эффект на само отношение — деление на $\bar{N}_1$. Без ковариат интервал даёт дельта-метод (Deng et al., 2018).
Вывод распространяется на всех будущих пользователей (PATE), а не только на участников теста	Лин + HC2 с поправкой (7); при слабой зависимости эффекта от ковариат поправка мала. Если когорта нерепрезентативна, нужно перевзвешивание к популяции.

2. Регрессия Лина: форма и свойства

Постановка. n пользователей (единиц рандомизации), потенциальные исходы $Y_i(1), Y_i(0)$, ковариаты $X_i \in \mathbb{R}^K$ измерены до назначения, $T_i \in \{0,1\}$; наблюдаем $Y_i = T_i Y_i(1) + (1-T_i) Y_i(0)$. При полной рандомизации ровно $n_1 = pn$ пользователей случайно попадают в тестовую группу. Оцениваемая величина — эффект на участниках теста $\tau_{\mathrm{SATE}} = n^{-1} \sum_i \big(Y_i(1) - Y_i(0)\big)$ или в популяции, из которой они выбраны, $\tau_{\mathrm{PATE}} = \mathbb{E}[Y(1) - Y(0)]$.

Модель. С центрированными ковариатами $\tilde{X}_i = X_i - \bar{X}$ (среднее по *всей* выборке) оценка Лина — коэффициент при T_i в OLS-регрессии

$$Y_i = \alpha + \tau T_i + \tilde{X}_i^\top \beta + T_i \, \tilde{X}_i^\top \gamma + e_i, \qquad W_i = (1, T_i, \tilde{X}_i^\top, T_i \tilde{X}_i^\top)^\top \in \mathbb{R}^P, \; P = 2K + 2. \tag{1}$$

Закрытая форма. Пусть $\hat\beta_1, \hat\beta_0$ — OLS-наклоны регрессии Y на X отдельно в тестовой и контрольной группах. Тогда (доказательство — в приложении A)

$$\hat\tau_L = \Big[\bar Y_1 - (\bar X_1 - \bar X)^\top \hat\beta_1\Big] - \Big[\bar Y_0 - (\bar X_0 - \bar X)^\top \hat\beta_0\Big] = \frac{1}{n}\sum_{i=1}^{n}\big(\hat\mu_1(X_i) - \hat\mu_0(X_i)\big), \tag{2}$$

где $\hat\mu_t$ — линейный прогноз по группе t. Формулу можно прочитать двумя способами:
- среднее каждой группы сдвигается к общему среднему ковариат по своему наклону;
- для каждого пользователя предсказываются оба потенциальных исхода, и их разность усредняется.

Частные случаи: при $K = 0$ это разность средних, при $\hat\beta_1 = \hat\beta_0$ — ANCOVA.

Оптимальный коэффициент. Все методы таблицы 1 лежат в классе $\hat\tau(\theta) = (\bar Y_1 - \bar Y_0) - \theta^\top(\bar X_1 - \bar X_0)$. При полной рандомизации и *фиксированном* заранее θ каждая такая оценка несмещена; если $\hat\theta$ оценён по тем же данным, смещение имеет порядок $O(1/n)$. Дисперсия минимальна при

$$\theta^* = (1-p)\,\beta_1 + p\,\beta_0, \qquad \beta_t = \Sigma_X^{-1}\,\mathrm{Cov}\big(X, Y(t)\big). \tag{3}$$

Формулу (2) можно переписать как $\hat\tau_L = (\bar Y_1 - \bar Y_0) - \big[(1-p)\hat\beta_1 + p\hat\beta_0\big]^\top(\bar X_1 - \bar X_0)$: Лин оценивает именно θ^*.

Критика Фридмана и ответ Лина. ANCOVA и CUPED с θ по всей выборке сходятся к коэффициенту с *перепутанными весами* $p\beta_1 + (1-p)\beta_0$. Их потеря точности по сравнению с Лином равна

$$n\big[\mathrm{Var}\,\hat\tau_{\mathrm{ANCOVA}} - \mathrm{Var}\,\hat\tau_L\big] \;\to\; \frac{(1-2p)^2}{p(1-p)}\,(\beta_1-\beta_0)^\top\Sigma_X(\beta_1-\beta_0) \;\geq 0. \tag{4}$$

Потеря нулевая при $p = 1/2$ или одинаковых наклонах, но в остальных случаях может сделать ANCOVA хуже разности средних. Freedman (2008) выдвинул три претензии к регрессионной корректировке: потеря точности, невалидная классическая ошибка и смещение на малых выборках. Lin (2013) показал, что в больших выборках все три либо несущественны, либо легко устраняются. С взаимодействиями точность асимптотически не хуже разности средних; сэндвич-ошибка (с взаимодействиями или без) асимптотически валидна или консервативна; смещение имеет порядок $O(1/n)$.

Асимптотика. Обозначим через $e_i(t)$ остатки линейных проекций $Y_i(t)$ на ковариаты, а через $S^2_\cdot$ — дисперсии по n пользователям. При полной рандомизации, фиксированном K и стандартных условиях на моменты (Lin, 2013; Li and Ding, 2017)

$$\sqrt{n}\,(\hat\tau_L - \tau_{\mathrm{SATE}}) \xrightarrow{d} \mathcal{N}\big(0, \sigma_L^2\big), \qquad \sigma_L^2 = \frac{S^2_{e(1)}}{p} + \frac{S^2_{e(0)}}{1-p} - S^2_{e(1)-e(0)}. \tag{5}$$

Для разности средних формула та же с исходами $Y_i(t)$ вместо остатков (дисперсия Неймана, Neyman, 1923), и $\sigma_L^2 \leq \sigma^2_{\mathrm{DM}}$. Результат *агностичен*: линейная модель не обязана быть верной, неверная спецификация лишь уменьшает выигрыш.

3. Стандартные ошибки: классическая, HC0–HC3

Пусть $\hat e_i$ — остатки регрессии (1), $h_{ii} = W_i^\top(W^\top W)^{-1}W_i$ — рычаг наблюдения. Все робастные варианты имеют вид сэндвича

$$\hat V = (W^\top W)^{-1}\Big(\sum_{i=1}^{n}\omega_i\,W_iW_i^\top\Big)(W^\top W)^{-1}, \qquad \widehat{\mathrm{SE}}(\hat\tau_L) = \sqrt{\hat V_{TT}}, \tag{6}$$

а различаются только весом ω_i (табл. 3).

Таблица 3. Варианты стандартной ошибки (MacKinnon and White, 1985; Long and Ervin, 2000).

Вариант	Вес ω_i	Свойства и где встречается
Классическая	$\hat\sigma^2 = \frac{\sum_j \hat e_j^2}{n-P}$ (общий для всех)	Предполагает одинаковый разброс остатков. Для разности средних это t-тест Стьюдента с объединённой дисперсией: при сплите 50/50 его ошибка в точности равна ошибке Уэлча; при неравном сплите он антиконсервативен, если *меньшая* группа имеет *бóльшую* дисперсию, и консервативен в обратном случае.
HC0 (White)	$\hat e_i^2$	Состоятельна, но на малых выборках занижает дисперсию: остатки OLS «прилипают» к данным, $\mathbb{E}\hat e_i^2 \approx \sigma_i^2(1-h_{ii})$.
HC1	$\frac{n}{n-P}\,\hat e_i^2$	HC0 с общей поправкой на число параметров. Опция `robust` в Stata.
HC2	$\frac{\hat e_i^2}{1-h_{ii}}$	Поправка на рычаг каждого наблюдения; несмещена при одинаковом разбросе. Без ковариат *в точности равна* дисперсии Уэлча $s_1^2/n_1 + s_0^2/n_0$ (Samii and Aronow, 2012). Imbens and Kolesár (2016) рекомендуют её вместе со степенями свободы Белла–Маккаффри. По умолчанию в `estimatr::lm_lin` (Blair et al., 2024). **Выбор по умолчанию.**
HC3	$\frac{\hat e_i^2}{(1-h_{ii})^2}$	Приближение jackknife, консервативнее HC2. Рекомендуется при малых выборках (Long and Ervin, 2000).

При $n \to \infty$ и $\max_i h_{ii} \to 0$ все варианты HC совпадают. Различия важны только при малом числе наблюдений на параметр. Проверка на симуляциях (рис. 1; сплит 30/70, $K = 5$, гетероскедастичность, 4000 симуляций на точку):

- $n = 40$ (в тестовой группе 12 наблюдений на 6 параметров группы): покрытие 95%-интервала у HC2 0.928, у HC3 0.984;
- $n = 80$: 0.945 и 0.972;
- $n = 200$: 0.951 и 0.963;
- $n = 1000$: оба ≈ 0.955.

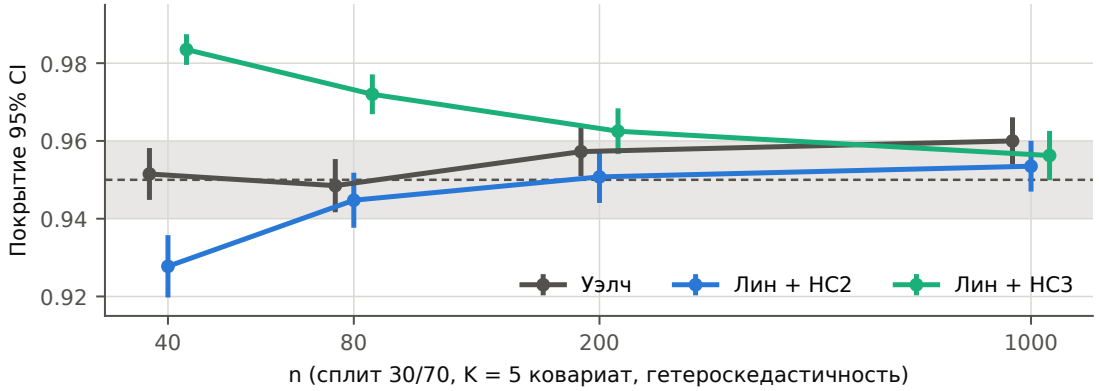


Рис. 1. Покрытие 95%-интервала при малых выборках (полосы — ±1.96 ошибки Монте-Карло).

Интервал и p-value. $\hat\tau_L \pm t_{1-\alpha/2,\nu}\widehat{\mathrm{SE}}$, $p = 2\big(1 - F_{t_\nu}(|\hat\tau_L|/\widehat{\mathrm{SE}})\big)$. На стенде используется $\nu = n - P$. Без ковариат это $n-2$, а не степени свободы Саттертуэйта, как у теста Уэлча; разница заметна только при очень малых или сильно неравных группах, и для них лучше степени свободы Белла–Маккаффри (Bell and McCaffrey, 2002; Imbens and Kolesár, 2016).

Что оценивает HC2: SATE или PATE. SATE — средний эффект на тех пользователях, что попали в эксперимент; PATE — эффект в популяции, из которой они случайно выбраны (именно он нужен, когда решение распространяется на будущих пользователей). С ковариатами HC2 асимптотически совпадает с нейманновской оценкой на остатках $\hat s_{e,1}^2/n_1 + \hat s_{e,0}^2/n_0$. Слагаемое $-S^2_{e(1)-e(0)}$ из (5) она не учитывает, поэтому *для SATE она консервативна* (Lin, 2013; Li and Ding, 2017). Для PATE нужно ещё учесть случайность средних ковариат (Negi and Wooldridge, 2021):

$$\widehat{\mathrm{Var}}_{\mathrm{PATE}}(\hat\tau_L) = \hat V_{TT} + \frac{1}{n}\,\hat\gamma^\top \hat\Sigma_X \hat\gamma, \qquad \hat\gamma = \hat\beta_1 - \hat\beta_0. \tag{7}$$

Поправка ненулевая только при разных наклонах в группах. Без неё интервал для PATE антиконсервативен: в нашей проверке покрытие было 0.931 без поправки и 0.953 с ней (табл. 5).

Мощность и MDE. При доле объяснённой ковариатами дисперсии R^2 (её нужно оценивать *вне* выборки, например на истории)

$$\mathrm{SE} \approx \sigma_Y \sqrt{1-R^2}\sqrt{\tfrac{1}{n_1}+\tfrac{1}{n_0}}\left(1+\tfrac{K}{n}\right)^{1/2}, \qquad \mathrm{MDE}_{80\%} \approx (t_{0.975,\nu} + t_{0.80,\nu})\ \mathrm{SE}\,.$$

Нужный объём выборки уменьшается в $1/(1-R^2)$ раз. Поправка $1+K/n$ — первый порядок при сплите 50/50; она такая же, как у ANCOVA, то есть взаимодействия почти ничего не стоят. На стенде при $R^2 = 0.4$, $n = 200$, $K = 5$ прогноз снижения дисперсии $1 - 0.6\,(1 + 5/200) \approx 0.385$ согласуется с наблюдаемыми 0.37–0.41 (1000 симуляций, ошибка Монте-Карло ≈ 0.025).

4. ML-прогноз как ковариата: CUPAC и ML-RATE

При нелинейном сигнале или большом числе признаков их сворачивают в один прогноз $\hat{g}(X)$ (Poyarkov et al., 2016; Li, 2020; Guo et al., 2021) и подставляют в (1) вместо X:

$$Y_i = \alpha + \tau T_i + \beta(\hat{g}_i - \bar{\hat{g}}) + \delta\, T_i(\hat{g}_i - \bar{\hat{g}}) + e_i.$$

Вывод остаётся (асимптотически) валидным при *любом* качестве модели, если прогноз $\hat{g}_i$ строится по признакам до воздействия, модель не видит T и не использует исход Y_i самого пользователя. Допустимы два способа обучения:

- **только на предпериоде** (temporal CUPAC): модель учится предсказывать прошлый период по позапрошлому и применяется со сдвигом;
- **cross-fitting** (ML-RATE): выборка делится на фолды, и модель для фолда k обучается на исходах Y остальных фолдов, без T в признаках (Chernozhukov et al., 2018).

Обучение на исходах эксперимента с применением к тем же строкам *запрещено*. Для линейного сглаживателя $\hat{g} = SY$ получаем $\mathbb{E}\hat{\tau} \approx \tau(1 - \mathrm{tr}\, S/n)$: эффект «съедается», а снижение дисперсии выглядит лучше, чем есть.

Лаг самой метрики полезно оставлять второй ковариатой *финальной* регрессии рядом с $\hat{g}$. Тогда метод асимптотически не хуже Лина на одном лаге, даже если модель деградировала (например, из-за дрейфа у temporal CUPAC). В текущей реализации стенда лаг входит только в признаки модели, и эта гарантия к ней не относится.

В оригинальной статье MLRATE используется аналитическая дисперсия и нормальный квантиль; HC2 и t-квантиль — выбор VarWar.

5. Численная проверка

VarWar — наш стенд для сравнения методов на синтетических данных с известным истинным эффектом. Каждый «сценарий» — способ генерации данных; для каждого делается R симуляций, и все методы считаются на одних и тех же сгенерированных данных.

Основной сценарий. $n = 200$, сплит 50/50, ковариаты объясняют 40% дисперсии метрики, $R = 1000$ симуляций. Доля ложных срабатываний (FPR) оценена без эффекта, остальные метрики — при эффекте 0.2σ. CUPED и CUPAC будут добавлены после пересчёта стенда (в предыдущей версии их стандартная ошибка считалась некорректно; на Лин и ML-RATE это не влияло).

Таблица 4. Основной сценарий ($R = 1000$). ΔVar — снижение дисперсии относительно Уэлча, мс — медианное время расчёта. 95% интервал Уилсона для FPR: Уэлч и ML-RATE [0.036; 0.062], Лин [0.036; 0.063].

Метод	FPR	Покрытие	Смещение	SE/SD	RMSE	ΔVar	Мощность	мс
Уэлч (разность средних)	0.047	0.955	−0.0035	1.04	0.135	—	0.265	5.3
Лин + HC2	**0.048**	**0.954**	−0.0044	1.03	**0.108**	0.37	0.404	6.6
ML-RATE (линейный прогноз) + HC2	0.047	0.955	−0.0024	1.03	0.109	0.35	0.405	16.5

Смещения неотличимы от нуля (ошибка Монте-Карло 0.003–0.004). SE/SD отличается от единицы в пределах ошибки Монте-Карло (около 2% при $R = 1000$): эффект в этом сценарии однородный, поэтому HC2, как и Уэлч, здесь не консервативна, а асимптотически точна. ML-RATE с линейным прогнозом по тем же признакам очень близок к Лину, но чуть хуже: MSE на $\approx 3\%$ выше.

Все 24 сценария (быстрый прогон, $R = 200$; рис. 2).

- Лин значимо снижает MSE в 20 сценариях: на 23–49% при умеренном сигнале и на 74–81% при $R^2 = 0.8$. Выигрыш сохраняется при тяжёлых хвостах и неравном разбросе.
- В трёх сценариях выигрыш 1–4% и в пределах шума: нет сигнала при $n = 2000$, нелинейные взаимодействия с 24 шумовыми признаками и счётчик с избытком нулей.
- Без сигнала при $n = 200$ MSE на 6% выше: это плата за 10 лишних параметров.
- FPR относительно истинного эффекта — 0.025–0.065, что совместимо с 0.05 при $R = 200$.

Для основного сценария быстрый прогон даёт -27% против -37% в подробном: это разброс Монте-Карло при 200 симуляциях. Две пары сценариев («сдвиг исторической панели»/«дрейф во времени» и «Гаусс, $R^2 = 0.4$, $n = 2000$»/«неверная историческая оценка») для Лина совпадают: они различаются только историческими данными, которые Лин не использует.

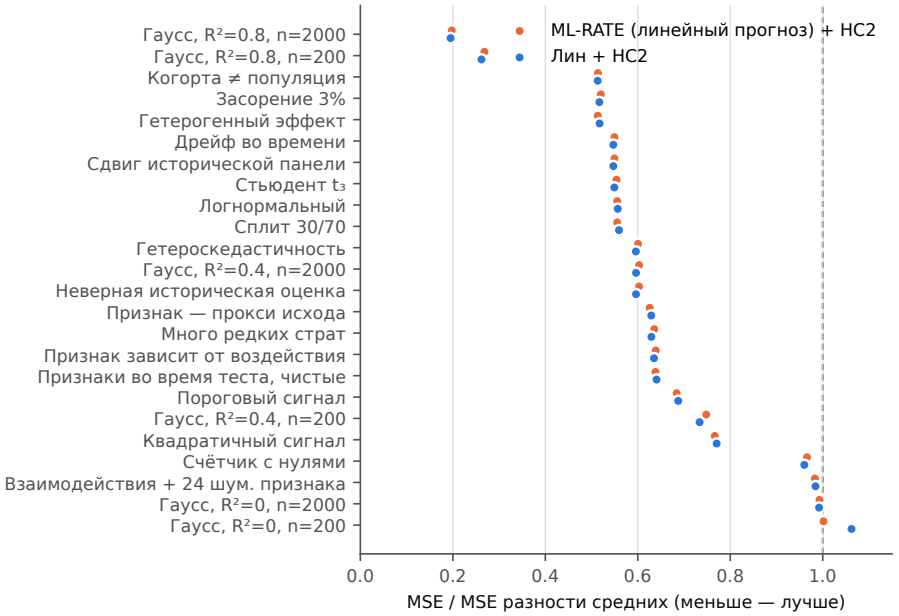


Рис. 2. Отношение MSE к MSE разности средних в 24 синтетических сценариях ($R = 200$; меньше — лучше). ML-RATE здесь использует линейный прогноз, поэтому почти совпадает с Лином. Сценарии «признаки во время теста» проверяют утечку для CUPAC; для Лина они не отличаются от обычных. В сценарии «когорта ≠ популяция» эффект на участниках отличается от эффекта в популяции.

Пример Фридмана (скрипт `sim_theory.py`, 4000 симуляций): $Y(0) = x + \varepsilon_0$, $Y(1) = \varepsilon_1$, $n = 400$ (табл. 5, рис. 3). Там же проверены тождества: закрытая форма (2) совпадает с OLS до $2 \cdot 10^{-15}$, HC2 без ковариат совпадает с Уэлчем до $3 \cdot 10^{-17}$. Высокое покрытие SATE (0.98–0.999 у всех методов) — проявление консервативности для SATE: эффект здесь сильно неоднороден ($\tau_i = -x_i + \varepsilon_{1i} - \varepsilon_{0i}$).

Таблица 5. Пример Фридмана: дисперсия относительно разности средних и покрытие 95%-интервала.

Метод	$p = 0.2$ Var/Var$_{\text{DM}}$	$p = 0.2$ Покр. SATE	$p = 0.2$ Покр. PATE	$p = 0.5$ Var/Var$_{\text{DM}}$	$p = 0.5$ Покр. SATE	$p = 0.5$ Покр. PATE
Разность средних (Уэлч)	1.00	0.989	0.953	1.00	0.995	0.954
CUPED, общий θ	1.40	0.983	0.953	0.68	0.999	0.951
ANCOVA + HC2	1.42	0.982	0.951	0.68	0.999	0.951
Лин + HC2	**0.95**	0.983	0.931	0.68	0.996	0.920
Лин + HC2 + поправка (7)	0.95	0.989	**0.953**	0.68	0.999	**0.951**

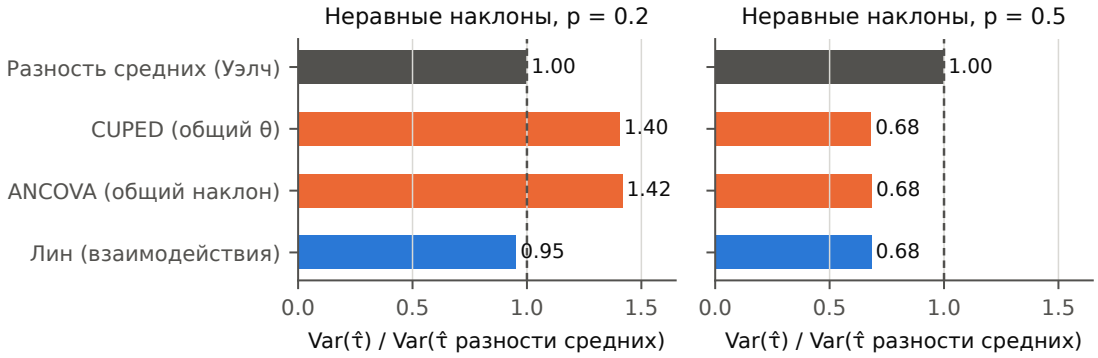


Рис. 3. Пример Фридмана. При $p = 0.2$ оценки с общим коэффициентом проигрывают даже разности средних, Лин — нет; при $p = 0.5$ все корректировки совпадают и снижают дисперсию на 32%.

Ограничение. Подробная проверка ($R = 1000$) пока сделана для одного сценария. Сценарии с неравным сплитом, панельной и нелинейной метрикой и сравнение с CUPED/CUPAC войдут в следующий прогон.

Список литературы

R. M. Bell, D. F. McCaffrey. Bias reduction in standard errors for linear regression with multi-stage samples. *Survey Methodology*, 28(2):169–181, 2002.

G. Blair, J. Cooper, A. Coppock, M. Humphreys, L. Sonnet. *estimatr: Fast Estimators for Design-Based Inference*. R package. https://declaredesign.org/r/estimatr/

R. Budylin, A. Drutsa, I. Katsev, V. Tsoy. Consistent transformation of ratio metrics for efficient online controlled experiments. *WSDM*, 2018.

V. Chernozhukov et al. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1):C1–C68, 2018.

A. Deng, Y. Xu, R. Kohavi, T. Walker. Improving the sensitivity of online controlled experiments by utilizing pre-experiment data. *WSDM*, 2013.

A. Deng, U. Knoblich, J. Lu. Applying the delta method in metric analytics: A practical guide with novel ideas. *KDD*, 2018.

D. A. Freedman. On regression adjustments to experimental data. *Advances in Applied Mathematics*, 40(2):180–193, 2008.

Y. Guo, D. Coey, M. Konutgan, W. Li, C. Schoener, M. Goldman. Machine learning for variance reduction in online experiments. *NeurIPS*, 2021.

G. W. Imbens, M. Kolesár. Robust standard errors in small samples: Some practical advice. *Review of Economics and Statistics*, 98(4):701–712, 2016.

G. W. Imbens, D. B. Rubin. *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press, 2015.

J. Li. Improving experimental power through control using predictions as covariate (CUPAC). Блог DoorDash Engineering, 2020. https://careersatdoordash.com/blog/improving-experimental-power-through-control-using-predictions-as-covariate-cupac/

X. Li, P. Ding. General forms of finite population central limit theorems with applications to causal inference. *JASA*, 112(520):1759–1769, 2017.

W. Lin. Agnostic notes on regression adjustments to experimental data: Reexamining Freedman's critique. *The Annals of Applied Statistics*, 7(1):295–318, 2013.

J. S. Long, L. H. Ervin. Using heteroscedasticity consistent standard errors in the linear regression model. *The American Statistician*, 54(3):217–224, 2000.

J. G. MacKinnon, H. White. Some heteroskedasticity-consistent covariance matrix estimators with improved finite sample properties. *Journal of Econometrics*, 29(3):305–325, 1985.

A. Negi, J. M. Wooldridge. Revisiting regression adjustment in experiments with heterogeneous treatment effects. *Econometric Reviews*, 40(5):504–534, 2021.

J. Neyman. On the application of probability theory to agricultural experiments (1923; transl. *Statistical Science*, 5(4):465–472, 1990).

A. Poyarkov, A. Drutsa, A. Khalyavin, G. Gusev, P. Serdyukov. Boosted decision tree regression adjustment for variance reduction in online controlled experiments. *KDD*, 2016.

C. Samii, P. M. Aronow. On equivalencies between design-based and regression-based variance estimators for randomized experiments. *Statistics & Probability Letters*, 82(2):365–370, 2012.

H. White. A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4):817–838, 1980.

A. Доказательства

Закрытая форма (2). Регрессия (1) насыщена по группам: у каждой группы свои свободный член и наклоны, поэтому её подгонка совпадает с двумя отдельными регрессиями. В контроле $\hat{\alpha}+\tilde{x}^\top\hat{\beta}=\hat{\mu}_0(x)$, в тестовой группе $\hat{\alpha}+\hat{\tau}+\tilde{x}^\top(\hat{\beta}+\hat{\gamma})=\hat{\mu}_1(x)$. При $x=\bar{X}$ получаем $\hat{\tau}=\hat{\mu}_1(\bar{X})-\hat{\mu}_0(\bar{X})=n^{-1}\sum_i(\hat{\mu}_1(X_i)-\hat{\mu}_0(X_i))$ (по линейности), а $\hat{\mu}_t(\bar{X})=\bar{Y}_t+(\bar{X}-\bar{X}_t)^\top\hat{\beta}_t$, поскольку OLS-гиперплоскость проходит через $(\bar{X}_t,\bar{Y}_t)$.

HC2 без ковариат равна Уэлчу. При $W_i=(1,T_i)$ рычаг $h_{ii}=1/n_{T_i}$, остаток — отклонение от среднего своей группы. Тогда $\sum_{i:T_i=t}\hat{e}_i^2/(1-1/n_t)=n_t s_t^2$, и элемент сэндвича для τ равен $\sum_t n_t s_t^2/n_t^2=s_1^2/n_1+s_0^2/n_0$.

Оптимальный коэффициент и потеря (4). $\hat{\tau}(\theta)$ — разность средних исхода $Y_i(t)-\theta^\top X_i$, поэтому по Нейману (Neyman, 1923; Imbens and Rubin, 2015) $n\operatorname{Var}\hat{\tau}(\theta)=S_1^2(\theta)/p+S_0^2(\theta)/(1-p)-S_\tau^2$, где $S_t^2(\theta)=S_{Y(t)}^2-2\theta^\top S_{XY(t)}+\theta^\top S_{XX}\theta$. Условие первого порядка $S_{XX}\theta\left(\frac{1}{p}+\frac{1}{1-p}\right)=\frac{S_{XY(1)}}{p}+\frac{S_{XY(0)}}{1-p}$ даёт $\theta^*=(1-p)\beta_1+p\beta_0$. Функция квадратична по θ, поэтому для $\theta_{\text{pool}}=p\beta_1+(1-p)\beta_0$ потеря равна $\left(\frac{1}{p}+\frac{1}{1-p}\right)(\theta_{\text{pool}}-\theta^*)^\top S_{XX}(\theta_{\text{pool}}-\theta^*)=\frac{(1-2p)^2}{p(1-p)}(\beta_1-\beta_0)^\top S_{XX}(\beta_1-\beta_0)$.

Поправка для PATE (7). Пусть $\mu_t(x)$ — линейные проекции $Y(t)$ на X в популяции, $\gamma=\beta_1-\beta_0$. Тогда $\tau_{\text{PATE}}=\mu_1(\mathbb{E}X)-\mu_0(\mathbb{E}X)$, а $\hat{\tau}_L-\tau_{\text{PATE}}=\left[\hat{\tau}_L-(\mu_1(\bar{X})-\mu_0(\bar{X}))\right]+(\bar{X}-\mathbb{E}X)^\top\gamma$. Первое слагаемое — ошибка, которую оценивает HC2; второе — выборочная ошибка $\bar{X}$ с дисперсией $\gamma^\top\Sigma_X\gamma/n$; асимптотически они некоррелированы (Negi and Wooldridge, 2021).