Регрессионная корректировка Лина с робастной дисперсией HC2 для анализа A/B-тестов

Теория, реализация в VarWar и численная проверка

VarWar R&D, ветка `rerun/v3.1`

20 октября 2026

Аннотация

Отчёт описывает пайплайн подведения итогов A/B-теста, который по результатам ревизии R&D VarWar v3 выглядит наиболее перспективным: полная рандомизация, без преобразования метрики, *регрессионная корректировка Лина* (OLS с центрированными предэкспериментальными ковариатами и их взаимодействиями с воздействием) и робастная ковариационная матрица *HC2* с t-квантилем. Мы выводим эстиматор и его закрытую форму, объясняем, почему он асимптотически не хуже разности средних и ANCOVA/CUPED при любом соотношении групп (ответ Лина на критику Фридмана), и подробно разбираем статистический вывод: консервативность HC2 для выборочного эффекта (SATE), поправку для популяционного эффекта (PATE), поведение при малых выборках, мощность и MDE. Численная часть опирается на результаты стенда VarWar v3 (1000 реализаций в подтверждающем мире и 200 реализаций в 24 мирах) и на независимые Monte-Carlo проверки. В подтверждающем мире ($n = 200$, $R^2 = 0.4$) Lin+HC2 сохраняет номинальный размер теста ($\widehat{\mathrm{FPR}} = 0.048$) и покрытие (0.95), снижая MSE на 37% относительно разности средних. Полный пересчёт по всем мирам подготовлен и выполняется отдельно.

Содержание

1 Контекст и выбор пайплайна **2**

2 Постановка задачи **2**

3 Эстиматор **3**
3.1 Модель и закрытая форма . . . 3
3.2 Класс линейно скорректированных оценок и оптимальный коэффициент . . . 3
3.3 Критика Фридмана и ответ Лина . . . 4

4 Статистический вывод **4**
4.1 Асимптотическое распределение . . . 4
4.2 Робастная дисперсия HC2 . . . 4
4.3 Популяционный эффект и поправка . . . 5
4.4 Доверительный интервал, p-value и малые выборки . . . 5
4.5 Мощность и минимальный детектируемый эффект . . . 5

5 Обобщение: прогноз машинного обучения как ковариата **6**

6 Реализация в VarWar **6**

7 Численная проверка **7**
7.1 Подтверждающий мир стенда v3 7
7.2 Все миры screening 7
7.3 Независимые проверки теоретических утверждений 7

8 Когда метод проигрывает и как его применять **8**

9 Ограничения доказательной базы и пересчёт **9**

A Вывод оптимального коэффициента **10**

1. Контекст и выбор пайплайна

VarWar сравнивает *полные процедуры* анализа рандомизированного эксперимента:

$$\text{FeatureAdapter} \to \text{Structure} \to \text{Assignment} \to \text{TargetTransformer} \to \text{AnalysisMethod},$$

где `AnalysisMethod` --- согласованная пара «точечная оценка + статистический вывод». Каноническим идентификатором рассматриваемого пайплайна является

```
adapt.identity__structure.none__assign.complete_randomization__
        target.identity__analysis.lin_regression__hc2
```

Почему именно он. Ревизия стенда (46 подтверждённых находок, см. `docs/review/v3_review_design.md`) показала следующее.

1. Для пайплайнов с преобразованием метрики (CUPED, CUPAC) в v3 стандартная ошибка вычислялась по *исходной*, а не по преобразованной метрике, поэтому их размер теста, покрытие и мощность в опубликованных таблицах некорректны (исправлено в ветке `rerun/v3.1`, требуется пересчёт). Оценки Лина и ML-RATE используют *собственную* (нативную) SE и этой ошибкой не затронуты.
2. Среди процедур с корректным выводом Lin+HC2 имеет наименьший RMSE в подтверждающем мире и в большинстве миров screening, при этом он строго обобщает канонический бейзлайн стенда: без ковариат HC2 совпадает с Welch (Утверждение 2).
3. ML-RATE с линейным ridge-прогнозом в v3 численно неотличим от Лина: прогноз строится по тем же признакам. Нелинейный вариант (градиентный бустинг) добавлен в ветке `rerun/v3.1` и будет сравниваться при пересчёте.

2. Постановка задачи

Рассмотрим n единиц рандомизации (например, клиентов). У единицы i есть потенциальные исходы $Y_i(1)$, $Y_i(0)$ и вектор ковариат $X_i \in \mathbb{R}^K$, *измеренных до назначения воздействия* (предпериод). Индикатор воздействия $T_i \in \{0,1\}$; наблюдаем $Y_i = T_iY_i(1) + (1-T_i)Y_i(0)$ (SUTVA).

Определение 1 (Полная рандомизация)**.** Ровно n_1 из n единиц случайно выбираются в тестовую группу, все $\binom{n}{n_1}$ назначений равновероятны; $p = n_1/n$, $n_0 = n - n_1$.

Целевые величины (estimand):

$$\tau_{\text{SATE}} = \frac{1}{n}\sum_{i=1}^{n}\big(Y_i(1) - Y_i(0)\big), \qquad \tau_{\text{PATE}} = \mathbb{E}\big[Y(1) - Y(0)\big].$$

SATE --- эффект в экспериментальной когорте (основная дорожка стенда, `sample_ate`), PATE --- эффект в популяции, из которой когорта является случайной выборкой. В конечно-популяционной (дизайновой) постановке случайность возникает *только* из назначения; в суперпопуляционной --- ещё и из выборки единиц.

Требование «ковариаты до воздействия» принципиально: если X_i может зависеть от T_i, корректировка вычитает часть эффекта, и оценка смещается (в старом прототипе это давало смещение около 40%).

3. Эстиматор

3.1. Модель и закрытая форма

Пусть $\bar{X} = n^{-1}\sum_i X_i$ и $\tilde{X}_i = X_i - \bar{X}$ --- ковариаты, центрированные по *всей* выборке. Оценка Лина (Lin, 2013) --- коэффициент при T_i в OLS-регрессии

$$Y_i = \alpha + \tau T_i + \tilde{X}_i^\top \beta + T_i\, \tilde{X}_i^\top \gamma + e_i. \tag{1}$$

В матричной записи $W_i = (1, T_i, \tilde{X}_i^\top, T_i\tilde{X}_i^\top)^\top \in \mathbb{R}^{2K+2}$, $\hat{\theta} = (W^\top W)^{-1} W^\top Y$, $\hat{\tau}_L = \hat{\theta}_T$.

Утверждение 1 (Закрытая форма)**.** *Пусть $\hat{\beta}_1, \hat{\beta}_0$ --- OLS-наклоны регрессии Y на X (с константой) отдельно в тестовой и контрольной группах. Тогда*

$$\hat{\tau}_L = \Big[\bar{Y}_1 - (\bar{X}_1 - \bar{X})^\top \hat{\beta}_1\Big] - \Big[\bar{Y}_0 - (\bar{X}_0 - \bar{X})^\top \hat{\beta}_0\Big] = \frac{1}{n}\sum_{i=1}^{n}\big(\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i)\big), \tag{2}$$

где $\hat{\mu}_t(x)$ --- линейный прогноз, построенный по группе t.

Набросок. Регрессия (1) насыщена по группам: у каждой группы свои свободный член и наклоны, поэтому её подгонка совпадает с двумя отдельными регрессиями. В контроле $\hat{\alpha} + \tilde{x}^\top\hat{\beta} = \hat{\mu}_0(x)$, в тесте $\hat{\alpha} + \hat{\tau} + \tilde{x}^\top(\hat{\beta} + \hat{\gamma}) = \hat{\mu}_1(x)$. При $x = \bar{X}$ получаем $\hat{\tau} = \hat{\mu}_1(\bar{X}) - \hat{\mu}_0(\bar{X})$, а по линейности $\hat{\mu}_t(\bar{X}) = n^{-1}\sum_i \hat{\mu}_t(X_i)$. Наконец, $\hat{\mu}_t(\bar{X}) = \bar{Y}_t + (\bar{X} - \bar{X}_t)^\top\hat{\beta}_t$, так как OLS-прямая проходит через $(\bar{X}_t, \bar{Y}_t)$. □

Формула (2) даёт три полезные интерпретации:

- *скорректированные средние*: среднее каждой группы сдвигается к общему среднему ковариат по своему наклону;
- *импутация*: для каждой единицы оба потенциальных исхода предсказываются групповыми моделями, и разность усредняется по всей когорте;
- *частные случаи*: при $K = 0$ это разность средних $\hat{\tau}_{\mathrm{DM}} = \bar{Y}_1 - \bar{Y}_0$; при принудительно общем наклоне $\hat{\beta}_1 = \hat{\beta}_0$ это ANCOVA; CUPED с одной ковариатой и общим θ --- тот же класс.

Используя $\bar{X}_1 - \bar{X} = (1-p)(\bar{X}_1 - \bar{X}_0)$ и $\bar{X}_0 - \bar{X} = -p(\bar{X}_1 - \bar{X}_0)$,

$$\hat{\tau}_L = \hat{\tau}_{\mathrm{DM}} - \big[(1-p)\hat{\beta}_1 + p\,\hat{\beta}_0\big]^\top(\bar{X}_1 - \bar{X}_0). \tag{3}$$

3.2. Класс линейно скорректированных оценок и оптимальный коэффициент

Рассмотрим класс $\hat{\tau}(\theta) = \hat{\tau}_{\mathrm{DM}} - \theta^\top(\bar{X}_1 - \bar{X}_0)$ с фиксированным $\theta \in \mathbb{R}^K$. При полной рандомизации любая оценка класса несмещена для SATE, а её асимптотическая дисперсия

$$n\,\mathrm{Var}\,\hat{\tau}(\theta) \;\to\; \frac{\mathrm{Var}\big(Y(1) - \theta^\top X\big)}{p} + \frac{\mathrm{Var}\big(Y(0) - \theta^\top X\big)}{1-p} - \mathrm{Var}\big(\tau_i\big) \tag{4}$$

(последнее слагаемое не зависит от θ). Минимизация по θ даёт

$$\theta^* = (1-p)\,\beta_1 + p\,\beta_0, \qquad \beta_t = \Sigma_X^{-1}\,\mathrm{Cov}\big(X, Y(t)\big). \tag{5}$$

Сравнивая с (3), видим, что оценка Лина асимптотически использует именно θ^*: она *оптимальна в классе*.

3.3. Критика Фридмана и ответ Лина

ANCOVA (регрессия без взаимодействий) и CUPED с θ, оценённым по всей выборке, сходятся к коэффициенту с *перепутанными весами*: $\theta_{\text{pool}} = p\,\beta_1 + (1-p)\,\beta_0$ (Freedman, 2008). Подставляя в (4), получаем потерю эффективности

$$n\big[\operatorname{Var}\hat{\tau}_{\text{ANCOVA}} - \operatorname{Var}\hat{\tau}_L\big] \;\to\; \frac{(1-2p)^2}{p(1-p)}\,(\beta_1-\beta_0)^\top \Sigma_X (\beta_1-\beta_0) \;\geq 0. \tag{6}$$

Потеря исчезает при $p = 1/2$ или при одинаковых наклонах. При неравном сплите и гетерогенных наклонах ANCOVA/CUPED может оказаться *хуже разности средних*; Лин --- никогда (асимптотически). Пример из раздела 7: при $p = 0.2$, $\beta_0 = 1$, $\beta_1 = 0$ дисперсия ANCOVA и CUPED составляет 1.42 и 1.40 от дисперсии разности средних, а дисперсия Лина --- 0.95.

Фридман также указывал, что классическая OLS-дисперсия ANCOVA может быть несостоятельной. Лин показал, что обе претензии снимаются одновременно: нужны *взаимодействия* и *робастная (сэндвич) дисперсия.*

4. Статистический вывод

4.1. Асимптотическое распределение

Обозначим через $e_i(t) = Y_i(t) - \bar{Y}(t) - (X_i - \bar{X})^\top \beta_t$ остатки конечно-популяционных проекций потенциальных исходов на ковариаты, $S^2_{e(t)}$ --- их дисперсии, $S^2_{e(1)-e(0)}$ --- дисперсия разности.

Теорема 1 (Lin, 2013; Li and Ding, 2017)**.** *При полной рандомизации, фиксированном K, $p \to p_\infty \in (0,1)$ и стандартных условиях на моменты и рычаги ($\max_i h_{ii} \to 0$)*

$$\sqrt{n}\,(\hat{\tau}_L - \tau_{SATE}) \;\xrightarrow{d}\; \mathcal{N}\Big(0,\ \sigma_L^2\Big), \qquad \sigma_L^2 = \frac{S^2_{e(1)}}{p} + \frac{S^2_{e(0)}}{1-p} - S^2_{e(1)-e(0)}.$$

Кроме того, $\sigma_L^2 \leq \sigma^2_{DM}$ и $\sigma_L^2 \leq \sigma^2_{ANCOVA}$.

Результат *агностичен*: линейная модель не обязана быть верной. Неверная спецификация лишь уменьшает выигрыш в точности, но не ломает несмещённость (смещение имеет порядок $O(1/n)$) и не ломает вывод.

4.2. Робастная дисперсия HC2

Пусть $\hat{e}_i$ --- остатки регрессии (1), $h_{ii} = W_i^\top (W^\top W)^{-1} W_i$ --- рычаги. Семейство сэндвич-оценок:

$$\hat{V}_{\text{HC}m} = (W^\top W)^{-1}\Big(\sum_{i=1}^{n} \frac{\hat{e}_i^2}{(1-h_{ii})^m}\, W_i W_i^\top\Big)(W^\top W)^{-1}, \qquad m = 0,1,2 \;\;(\text{HC0, HC2, HC3}), \tag{7}$$

$\widehat{\text{SE}} = \sqrt{[\hat{V}]_{TT}}$ (White, 1980; MacKinnon and White, 1985).

Утверждение 2 (HC2 без ковариат = Welch)**.** *При $K = 0$ $[\hat{V}_{HC2}]_{TT} = s_1^2/n_1 + s_0^2/n_0$, где s_t^2 --- несмещённые выборочные дисперсии в группах.*

Набросок. При $W_i = (1, T_i)$ рычаг $h_{ii} = 1/n_{T_i}$, остаток --- отклонение от группового среднего. Тогда $\sum_{i:T_i=t} \hat{e}_i^2/(1-1/n_t) = n_t s_t^2$, и сэндвич для τ равен $\sum_t n_t s_t^2/n_t^2$. □

С ковариатами HC2 асимптотически эквивалентна нейманновской оценке на остатках:

$$[\hat{V}_{\text{HC2}}]_{TT} = \frac{\hat{s}^2_{e,1}}{n_1} + \frac{\hat{s}^2_{e,0}}{n_0} + o_p(n^{-1}).$$

Её математическое ожидание не учитывает отрицательный член $-S^2_{e(1)-e(0)}/n$ теоремы 1, поэтому

$$\mathbb{E}\,[\hat{V}_{\mathrm{HC2}}]_{TT} - \mathrm{Var}(\hat{\tau}_L) \approx \frac{S^2_{e(1)-e(0)}}{n} \geq 0\,: \tag{8}$$

для SATE оценка HC2 консервативна. Консервативность исчезает, если эффект линеен по X (остатки $e(1)$ и $e(0)$ совпадают), и это неустранимо: индивидуальные эффекты не наблюдаются.

4.3. Популяционный эффект и поправка

Если цель --- PATE, а когорта является случайной выборкой из популяции, к дисперсии добавляется неопределённость $\bar{X}$ как оценки $\mathbb{E}X$:

$$\widehat{\mathrm{Var}}_{\mathrm{PATE}}(\hat{\tau}_L) = [\hat{V}_{\mathrm{HC2}}]_{TT} + \frac{1}{n}\,\hat{\gamma}^\top \hat{\Sigma}_X \hat{\gamma}, \qquad \hat{\gamma} = \hat{\beta}_1 - \hat{\beta}_0. \tag{9}$$

Поправка ненулевая только при гетерогенных наклонах. Без неё интервал для PATE антиконсервативен: в нашей проверке покрытие PATE было 0.931 при $p = 0.2$ и 0.920 при $p = 0.5$, с поправкой --- 0.953 и 0.951 (табл. 3). Если веса целевой популяции отличаются от когорты (сдвиг популяции), оценка переносится как $\hat{\tau}_L + (\mu^* - \bar{X})^\top \hat{\gamma}$ с соответствующей дельта-методной дисперсией. Это отдельная дорожка `population_ate`: её нельзя ранжировать вместе с SATE.

4.4. Доверительный интервал, p-value и малые выборки

Интервал и двусторонний p-value:

$$\hat{\tau}_L \pm t_{1-\alpha/2,\,\nu}\,\widehat{\mathrm{SE}}, \qquad p = 2\Big(1 - F_{t_\nu}\big(|\hat{\tau}_L|/\widehat{\mathrm{SE}}\big)\Big), \qquad \nu = n - (2K+2).$$

Асимптотически квантиль нормальный; t_ν --- консервативная поправка на конечное n. Эквивалентно, тест отвергает $H_0 : \tau = 0$ ровно тогда, когда $0 \notin$ CI.

При малом числе наблюдений на параметр HC2 занижает дисперсию, так как остатки OLS «прилипают» к данным. Наша проверка (рис. 3, сплит 30/70, $K = 5$, гетероскедастичность) даёт следующее:

- при $n = 40$ (около 12 наблюдений в тестовой группе на 12 параметров) покрытие HC2 равно 0.928, HC3 --- 0.984 (перестраховка);
- при $n \geq 200$ оба варианта близки к 0.95.

Практическое правило: держать $K \ll \min(n_1, n_0)$ (ориентир --- не более $n_{\min}/20$); при малых n использовать HC3 или поправку числа степеней свободы Белла--Маккаффри (Bell and McCaffrey, 2002; Imbens and Kolesár, 2016).

4.5. Мощность и минимальный детектируемый эффект

Пусть R^2 --- доля дисперсии Y, объяснённая ковариатами внутри группы (вне выборки обучения). Тогда приближённо

$$\mathrm{SE}(\hat{\tau}_L) \approx \sigma_Y \sqrt{1-R^2}\,\sqrt{\frac{1}{n_1} + \frac{1}{n_0}}\,\Big(1 + O\big(\tfrac{K}{n}\big)\Big), \qquad \mathrm{MDE}_{1-\beta} = \big(t_{1-\alpha/2,\nu} + t_{1-\beta,\nu}\big)\,\mathrm{SE}\,.$$

Необходимый объём выборки уменьшается в $1/(1-R^2)$ раз; экономия равна R^2. Для дизайна эксперимента R^2 нужно брать из исторических данных вне выборки: in-sample R^2 оптимистичен. В подтверждающем мире VarWar ($R^2 = 0.4$, $n = 200$, $K = 5$) теоретическое снижение дисперсии составляет $1 - 0.6\,(1 + 10/200) = 0.37$, наблюдаемое --- 0.367 (табл. 2).

5. Обобщение: прогноз машинного обучения как ковариата

Если сигнал нелинеен или признаков много, ковариаты сворачиваются в один прогноз $\hat{g}(X)$ исхода (идея CUPAC и ML-RATE, Guo et al., 2021), который подаётся в (1) вместо X (или вместе с лагом самой метрики):

$$Y_i = \alpha + \tau T_i + \beta\big(\hat{g}_i - \bar{\hat{g}}\big) + \delta\, T_i\big(\hat{g}_i - \bar{\hat{g}}\big) + e_i.$$

Здесь критично, *на каких данных обучена* модель $\hat{g}$.

- **Только предпериод** (temporal CUPAC, «lag2→lag1»): $\hat{g}_i$ --- фиксированная функция данных до воздействия, и теория Лина применяется без изменений.
- **Cross-fitting** (ML-RATE): выборка делится на K_f фолдов, и $\hat{g}_i = \hat{g}^{(-k(i))}(X_i)$ обучается без фолда единицы i и без T. Условно на остальные фолды $\hat{g}_i$ --- функция только X_i, поэтому валидность сохраняется при любом качестве модели (Chernozhukov et al., 2018; Guo et al., 2021).
- **In-sample** (модель обучена на тех же исходах эксперимента и применена к тем же строкам) *запрещено*. Для линейного сглаживателя $\hat{g} = SY$ получаем $\mathbb{E}\hat{\tau} \approx \tau\,(1 - \operatorname{tr} S/n)$: часть эффекта «съедается», а снижение дисперсии завышается. Именно эта ошибка была в прототипах на реальных данных.

Включать лаг самой метрики в число ковариат полезно: тогда Лин с прогнозом асимптотически не хуже CUPED по этому лагу, даже если модель $\hat{g}$ деградировала из-за дрейфа.

6. Реализация в VarWar

Таблица 1. Где реализован пайплайн.

Компонент	Реализация
Регистрация	`analysis_registry.py`: метод `lin_regression__hc2` = `RegressionAdjustmentEstimator` с `covariance_type="HC2"`; estimand `sample_ate`; нативный вывод
Точка и SE	`estimators.py`: `RegressionAdjustmentEstimator.estimate` --- центрирование, матрица W, OLS через `lstsq`
Ковариация	`estimators.py`: `_robust_covariance` --- `pinv`$(W^\top W)$, h_{ii} через `einsum`, веса $\hat{e}_i^2 / \max(1 - h_{ii}, 10^{-12})$
CI и p-value	`estimators.py`: `_build_result` --- t_ν, $\nu = n - \dim W$
Ковариаты в гонке	`rnd_runner.py`: `_spec` --- `pre_target_lag1, x1, x2, x3, x4` ($K = 5$, $\dim W = 12$)

Численная сверка: оценка и SE (HC2 и HC3) совпадают со `statsmodels` до 10^{-15}; без ковариат SE совпадает с Welch. Изменения ветки `rerun/v3.1`, затрагивающие этот пайплайн:

- центрирование ковариат выполняется по строкам, реально участвующим в регрессии (раньше --- по всем строкам до фильтра пропусков);
- в диагностику выводится ранг матрицы плана (коллинеарность больше не маскируется `pinv`);
- миры с гетерогенным эффектом получили настоящую нулевую гипотезу для SATE (раньше «H0» в мире сдвига популяции имела SATE = 0.285, и FPR = 1 был мощностью);
- правила вердиктов учитывают Monte-Carlo-ошибку; seed не зависят от шардирования; нелинейный ML-RATE добавлен как конкурент.

Там же добавлены опции, относящиеся к выводу: вариант `lin_regression__hc2_pate` с поправкой (9) (только для дорожки `population_ate`; предполагает, что когорта --- iid-выборка из целевой популяции) и необязательные степени свободы Белла--Маккаффри для HC2 (по умолчанию выключены). Известное ограничение: категориальные ковариаты (`region`, `device`) в гонке не используются.

7. Численная проверка

7.1. Подтверждающий мир стенда v3

Мир `gaussian_r2_04_n200`: $n = 200$, сплит 50/50, $R^2 = 0.4$, 1000 реализаций, общие случайные числа для всех процедур (табл. 2). FPR оценён под H_0, остальные метрики --- при эффекте 0.2σ; в квадратных скобках --- 95% интервал Уилсона.

Таблица 2. Подтверждение (VarWar v3, $R = 1000$). Строки CUPED/CUPAC не приводятся: их SE в v3 была вычислена неверно.

Метод	FPR	Покрытие	Смещение	SD	$\overline{\text{SE}}$	SE/SD	RMSE
Welch (разность средних)	0.047 [0.036; 0.062]	0.955	−0.0035	0.135	0.141	1.04	0.135
Лин + HC2	**0.048** [0.036; 0.063]	**0.954**	−0.0044	**0.108**	0.111	1.03	**0.108**
ML-RATE (ridge, cross-fit) + HC2	0.047 [0.036; 0.062]	0.955	−0.0024	0.109	0.112	1.03	0.109

Метод	Снижение дисперсии vs Welch	Мощность при 0.2σ	Медиана времени, мс
Welch	---	0.265	5.3
Лин + HC2	0.37	0.404	6.6
ML-RATE + HC2	0.35	0.405	16.5

Монте-Карло-ошибка смещения около 0.0034, так что все смещения статистически неотличимы от нуля. SE/SD немного больше единицы, что согласуется с консервативностью (8) и t-квантилем. Мощность Лина (0.404) близка к теоретической (≈ 0.415).

7.2. Все миры screening

На рис. 1 показано отношение MSE к разности средних по 24 мирам (200 реализаций; эффект 0.2σ). Лин уменьшает MSE в 23 мирах из 24. Исключение --- мир без сигнала в ковариатах при $n = 200$: 1.06, плата за 10 лишних параметров. Снижение MSE составляет 25--50% в мирах с умеренным сигналом ($R^2 \approx 0.4$), 74--80% при сильном ($R^2 = 0.8$) и сохраняется при тяжёлых хвостах (Стьюдент t_3, логнормальное распределение, засорение) и при гетероскедастичности. Оценённый относительно истинного эффекта размер теста Лина лежит в диапазоне 0.025--0.075, что совместимо с номинальным при $R = 200$ (MC-ошибка ≈ 0.015). *Мир сдвига популяции* помечен звёздочкой: его «нулевая гипотеза» в v3 не была нулевой для SATE, поэтому FPR = 1 в исходном отчёте --- артефакт разметки, а не провал метода. Относительно истинного SATE размер теста Лина равен 0.050.

7.3. Независимые проверки теоретических утверждений

Самодостаточный скрипт `docs/reports/lin_hc2/sim_theory.py` (numpy, 4000 реализаций на сценарий) проверяет следующее.

- *Тождества*: $|\hat{\tau}_L - \text{закрытая форма}| = 1.8 \cdot 10^{-15}$; $|\,\text{SE}_{\text{HC2},K=0} - \text{SE}_{\text{Welch}}\,| = 3 \cdot 10^{-17}$.
- *Кейс Фридмана* (табл. 3, рис. 2): $Y(0) = x + \varepsilon_0$, $Y(1) = \varepsilon_1$, $n = 400$.
- *Малые выборки* (рис. 3).

Таблица 3. Кейс Фридмана: дисперсия относительно разности средних и покрытие 95% CI.

	$p = 0.2$			$p = 0.5$		
Метод	$\text{Var}/\text{Var}_{\text{DM}}$	Покр. SATE	Покр. PATE	$\text{Var}/\text{Var}_{\text{DM}}$	Покр. SATE	Покр. PATE
Разность средних (Welch)	1.00	0.989	0.953	1.00	0.995	0.954
CUPED, общий θ	1.40	0.983	0.953	0.68	0.999	0.951
ANCOVA + HC2	1.42	0.982	0.951	0.68	0.999	0.951
Лин + HC2	**0.95**	0.983	0.931	0.68	0.996	0.920
Лин + HC2 + поправка (9)	0.95	0.989	**0.953**	0.68	0.999	**0.951**

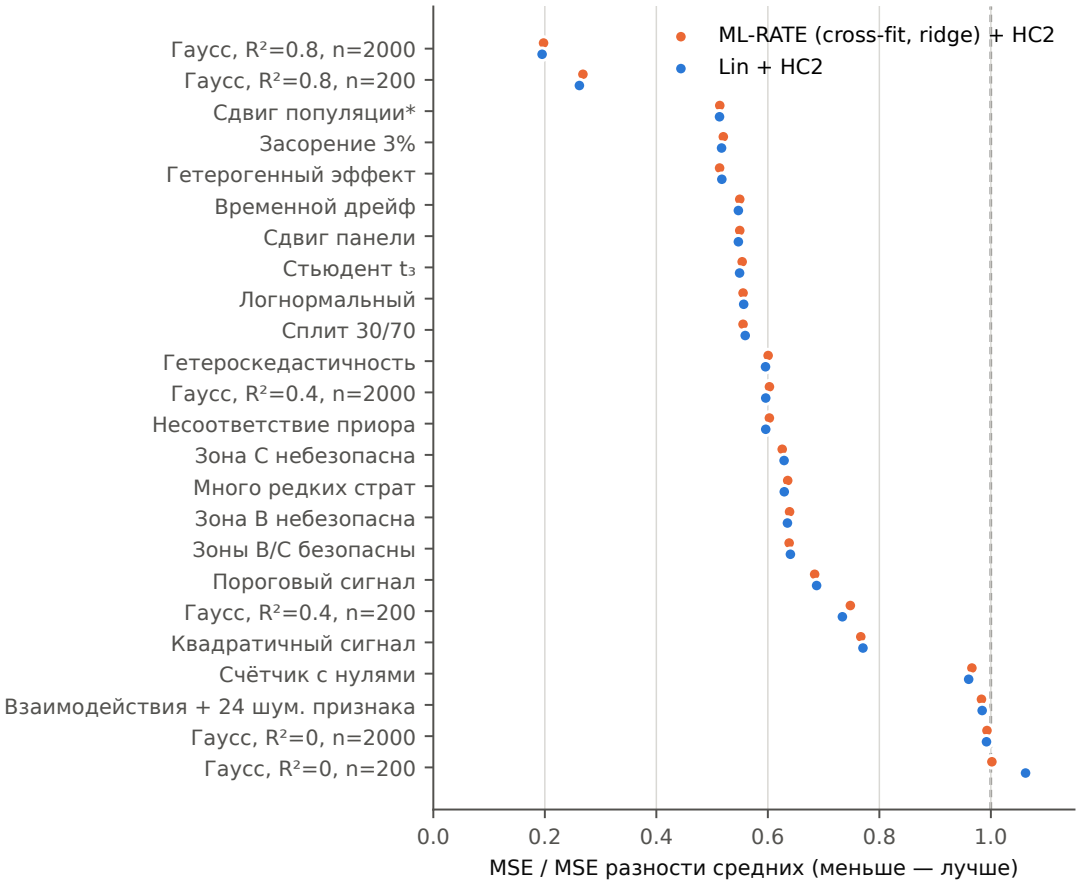


Рис. 1. MSE оценки эффекта относительно разности средних по мирам VarWar v3 (screening, $R = 200$). Пунктир --- уровень разности средних.

Высокое покрытие SATE в кейсе Фридмана (0.98--0.99) --- проявление консервативности (8): эффект здесь сильно гетерогенен ($\tau_i = -x_i + \varepsilon_{1i} - \varepsilon_{0i}$), и дизайновая дисперсия заметно меньше оцениваемой. Для PATE та же SE уже не консервативна, и нужна поправка.

8. Когда метод проигрывает и как его применять

Слабые места.

1. **Много ковариат при малом n и слабом сигнале.** Каждая ковариата стоит двух параметров; при $R^2 \approx 0$ и $n = 200$ MSE на 6% выше, чем у разности средних.
2. **Нелинейный сигнал.** Линейная проекция теряет часть R^2 (в мирах с квадратичным и пороговым сигналом снижение MSE 23--31% против $\approx 40\%$ в линейном мире того же R^2). Лекарство --- прогноз ML как ковариата (раздел 5), сравнение запланировано в пересчёте.
3. **Тяжёлые хвосты и выбросы.** OLS неробастна, хотя вывод остаётся валидным. Винзоризация исхода меняет estimand и должна фиксироваться заранее по предпериоду; преобразовывать ковариаты можно свободно.
4. **PATE и сдвиг популяции.** Без поправки (9) интервал антиконсервативен.
5. **Иные дизайны** (стратификация, рерандомизация). Лин остаётся валидным, но HC2 становится консервативной, а выигрыш над уже сбалансированным дизайном мал. Корректный вывод для рерандомизации требует отдельных формул.

Чек-лист применения.

- Единица анализа совпадает с единицей рандомизации.

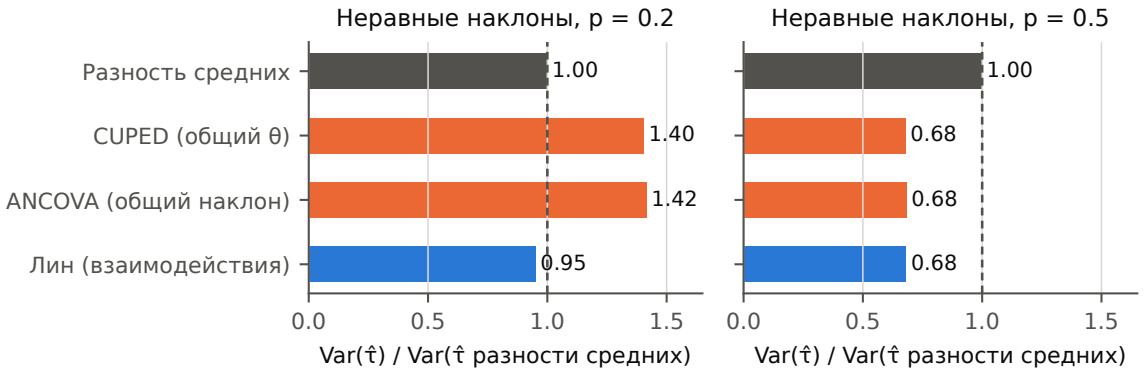


Рис. 2. При неравном сплите и разных наклонах оценки с общим коэффициентом проигрывают даже разности средних; Лин --- нет. При $p = 0.5$ все корректировки совпадают.

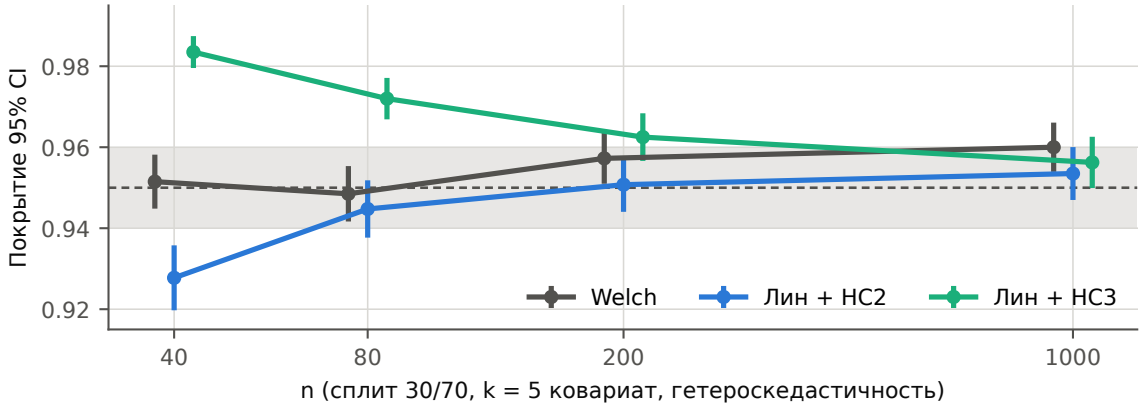


Рис. 3. Покрытие 95% CI при малых выборках (полосы --- ± 1.96 MC-ошибки, серая зона --- 0.95 ± 0.01).

- Ковариаты строго до воздействия; список фиксируется до эксперимента. Лаг самой метрики --- в первую очередь.
- $K \ll n_{\min}$; категориальные признаки --- дамми без референсного уровня; проверка ранга.
- Центрирование по всей анализируемой выборке; регрессия с взаимодействиями.
- SE: HC2 (HC3 при малых n); квантиль t_ν; для PATE --- поправка (9).
- Если используется ML-прогноз --- только предпериод или cross-fitting, без T в модели.
- Отчёт: оценка, CI, p-value, снижение дисперсии $1 - \hat{V}_L/\hat{V}_{\mathrm{DM}}$, баланс ковариат как диагностика (но не как условие анализа).

9. Ограничения доказательной базы и пересчёт

Сильные доказательства валидности и выигрыша Лина получены пока для одного подтверждающего мира ($R = 1000$); по остальным мирам доступен screening с $R = 200$ и коррелированными seed. Конкуренты с преобразованием метрики (CUPED, CUPAC) в v3 оценивались с неверной SE, поэтому их сравнение с Лином по валидности ещё не проведено. В ветке `rerun/v3.1` исправлены ошибки стенда и добавлены миры, где методы различаются по теории (неравный сплит с гетерогенностью, панельная метрика, нелинейный сигнал). Подготовлен пересчёт: screening по всем мирам ($R = 500$) и confirmation финалистов ($R = 2000$). Таблицы 2 и рис. 1 будут заменены по его итогам.

Список литературы

W. Lin. Agnostic notes on regression adjustments to experimental data: Reexamining Freedman's critique. *The Annals of Applied Statistics*, 7(1):295--318, 2013.

D. A. Freedman. On regression adjustments to experimental data. *Advances in Applied Mathematics*, 40(2):180--193, 2008.

X. Li, P. Ding. General forms of finite population central limit theorems with applications to causal inference. *JASA*, 112(520):1759--1769, 2017.

J. Neyman. On the application of probability theory to agricultural experiments (1923; transl. *Statistical Science*, 5(4):465--472, 1990).

H. White. A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4):817--838, 1980.

J. G. MacKinnon, H. White. Some heteroskedasticity-consistent covariance matrix estimators with improved finite sample properties. *Journal of Econometrics*, 29(3):305--325, 1985.

R. M. Bell, D. F. McCaffrey. Bias reduction in standard errors for linear regression with multi-stage samples. *Survey Methodology*, 28(2):169--181, 2002.

G. W. Imbens, M. Kolesár. Robust standard errors in small samples: Some practical advice. *Review of Economics and Statistics*, 98(4):701--712, 2016.

A. Deng, Y. Xu, R. Kohavi, T. Walker. Improving the sensitivity of online controlled experiments by utilizing pre-experiment data. *WSDM*, 2013.

Y. Guo, D. Coey, M. Konutgan, W. Li, C. Schoener, M. Goldman. Machine learning for variance reduction in online experiments. *NeurIPS*, 2021.

V. Chernozhukov et al. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1):C1--C68, 2018.

A. Negi, J. M. Wooldridge. Revisiting regression adjustment in experiments with heterogeneous treatment effects. *Econometric Reviews*, 40(5):504--534, 2021.

G. W. Imbens, D. B. Rubin. *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press, 2015.

A. Вывод оптимального коэффициента

Для фиксированного θ разложим $\hat\tau(\theta) = \overline{(Y-\theta^\top X)}_1 - \overline{(Y-\theta^\top X)}_0$ --- разность средних «скорректированного» исхода $Y_i(t) - \theta^\top X_i$. По теореме Неймана (Neyman, 1923; Imbens and Rubin, 2015) $n\operatorname{Var}\hat\tau(\theta) = S_1^2(\theta)/p + S_0^2(\theta)/(1-p) - S_\tau^2$, где $S_t^2(\theta) = S^2_{Y(t)} - 2\theta^\top S_{XY(t)} + \theta^\top S_{XX}\theta$. Условие первого порядка: $-2S_{XY(1)}/p - 2S_{XY(0)}/(1-p) + 2\big(1/p + 1/(1-p)\big)S_{XX}\theta = 0$, откуда $\theta^* = (1-p)\beta_1 + p\beta_0$ с $\beta_t = S_{XX}^{-1}S_{XY(t)}$. Подстановка $\theta_{\text{pool}} = p\beta_1 + (1-p)\beta_0$ даёт разность $(\theta_{\text{pool}} - \theta^*)^\top S_{XX}(\theta_{\text{pool}} - \theta^*)\big(1/p + 1/(1-p)\big) = (1-2p)^2(\beta_1-\beta_0)^\top S_{XX}(\beta_1-\beta_0)/(p(1-p))$, то есть (6).